

SignAI — Registro de Decisiones Arquitectónicas (ADR)

Versión: 0.1 **Fecha de creación:** 22 de julio de 2026 **Estado:** En construcción — se actualiza decisión por decisión

Qué es un ADR

ADR significa *Architecture Decision Record* (registro de decisión de arquitectura). Es un formato corto para dejar por escrito una decisión técnica importante: qué problema había, qué opciones se consideraron, cuál se eligió y por qué. No es una decisión sin más — es la decisión junto con su razonamiento, para que más adelante (el equipo, un nuevo integrante, el jurado de la tesis) entienda por qué se hizo así y no de otra forma.

Cada entrada de este documento es un ADR individual, numerado de forma independiente a su DEC asociado del backlog.

Cómo se usa este documento

Cada decisión pendiente del Architecture Backlog (sección DEC) se desarrolla aquí como una entrada corta cuando el equipo decide trabajarla. El orden de trabajo lo define el equipo, no la numeración del backlog.

Mecánica:

1. El equipo elige qué decisión trabajar.

2. Se discuten opciones, riesgos y trade-offs.
3. La entrada se redacta y el estado avanza según qué tan resuelta quede.
4. Al llegar a **Decidida**, se actualiza la fila correspondiente en la tabla de DEC del backlog, y si el Documento Maestro requiere cambios, se agrega la entrada correspondiente en la sección DOC del backlog.

Estados:

Estado	Significa
En análisis	Todavía no se ha discutido, o depende de un dato que no existe (spike, medición, información externa).
En evaluación	Ya se identificaron las opciones, pero la decisión está bloqueada por una tarea (TSK) pendiente.
Propuesta	Ya se discutió y hay una dirección clara, pero falta un dato para confirmarla del todo, o falta rematar un detalle.
Decidida	Queda firmada, con su justificación. No se revierte sin una razón nueva y documentada.

Nota: las decisiones que dependen de un spike o de información externa (DEC-01, 02, 03, 05, 06, 07, 16) pueden avanzar a "Propuesta" si hay una hipótesis fuerte, pero no pasan a "Decidida" sin el dato correspondiente.

Plantilla

```
### ADR-0XX – [nombre de la decisión]
Responsable: [nombre]
Estado: Propuesta / Decidida / En análisis / En evaluación
Bloqueada por: TSK-XX (si aplica; omitir si no hay bloque
Fecha:
Relacionado con: DEC-XX, INC-XX, TSK-XX
```

Contexto: (el problema, en 2-3 líneas)
Opciones: (qué se consideró, con pros/contras breves)
Decisión: (qué se eligió)
Consecuencias: (qué implica, qué queda pendiente, qué req

Nota sobre "Bloqueada por": cuando el estado es "En evaluación", esta línea va justo debajo del estado, no al final, para que sea imposible pasarla por alto: la decisión no avanza sin ese TSK.

Nota sobre "Relacionado con": se listan las DEC que esta decisión resuelve, las INC que quedan cerradas o parcialmente cerradas por ella, y las TSK que la ejecutan o que aportaron el dato con el que se decidió. No todas las decisiones tienen TSK asociada — varias se resuelven por discusión pura.

Índice de decisiones (26)

Estado inicial de todas: **En análisis**. Se actualiza aquí a medida que se trabajan.

ADR	Decisión	DEC	Estado
ADR-001	Alcance del deletreo y condiciones de activación	DEC-01	Propuesta
ADR-002	Composición del corpus de 50 señas	DEC-02	En análisis
ADR-003	Origen del avatar y requisitos del esqueleto	DEC-03	En evaluación
ADR-004	Proceso de producción de animaciones	DEC-04	En evaluación
ADR-005	Estrategia de transcripción en vivo	DEC-05	En evaluación

ADR-006	Modelo de Whisper y entorno de ejecución	DEC-06	En evaluación
ADR-007	Enfoque de NLP: solo LLM o reglas más LLM	DEC-07	En evaluación
ADR-008	Que el NLP indique el tipo de frase	DEC-08	Propuesta
ADR-009	Expresiones faciales como capa independiente	DEC-09	Propuesta
ADR-010	Contrato JSON definitivo backend–avatar	DEC-10	En análisis
ADR-011	Número de microservicios y fronteras	DEC-11	Decidida (enfoque) / detalle pendiente
ADR-012	Estrategia de archivos GLB	DEC-12	Propuesta
ADR-013	Tratamiento del audio y el texto	DEC-13	En análisis
ADR-014	Seguridad del backend y control de gasto del LLM	DEC-14	En análisis
—	ORM, migraciones y carga inicial del corpus	DEC-15	En análisis
—	Umbral de precisión de glosas	DEC-16	En análisis
—	Instrumento de evaluación y número de participantes	DEC-17	En análisis
—	Referencia de traducción (gold standard)	DEC-18	En análisis
—	Instrumentación de métricas en producción	DEC-19	En análisis
—	Definición de sesión e identificación del cliente	DEC-20	En análisis

—	Métricas que demuestren el valor de microservicios	DEC-21	En análisis
—	Condiciones de los audios de prueba	DEC-22	En análisis
—	Entorno de despliegue y demo de sustentación	DEC-23	En análisis
—	Condiciones de uso del material de INSOR/LSC50	DEC-24	En análisis
—	Cadencia de deletreo	DEC-25	En análisis
—	Numerales como subsistema distinto del alfabeto	DEC-26	En análisis

Decisiones desarrolladas

ADR-001 — Alcance del deletreo y condiciones de activación

Responsable: Julián — ya completado, falta validar con intérprete
Estado: **Propuesta** **Fecha:** 22/07/2026 **Relacionado con:** DEC-01, DEC-25, DEC-26, INC-01, INC-02 (parcial), RSK-20, TSK-02

Contexto: El corpus principal de 50 señas es cerrado. Cuando el NLP genera una glosa que no está en el corpus, hay que decidir qué responde el sistema. La opción original del Documento Maestro era devolver siempre "Seña no disponible". Se evaluó si conviene ampliar esa respuesta usando dactilología (deletreo letra por letra) en lugar de un simple rechazo.

Opciones consideradas:

1. **Solo "Seña no disponible".** Es la opción original del documento. Simple, pero para el usuario se siente como una falla total: el

sistema no comunica nada de la palabra.

2. **Deletrear únicamente nombres propios y números.** Reduce el alcance al caso más claro y lingüísticamente más aceptado de uso de dactilología. Deja sin cubrir cualquier otra palabra fuera de corpus (por ejemplo, "computador").
3. **Deletrear cualquier palabra fuera de corpus.** El sistema nunca responde con un rechazo puro: si la glosa no está en las 50 señas, se deletrea letra por letra. Es más lento para palabras largas, pero siempre comunica algo.

Decisión: Se adopta la opción 3. **El corpus de 50 señas mantiene prioridad total** — el sistema primero intenta resolver la glosa contra el corpus, y solo si no la encuentra recurre al deletreo letra por letra. El deletreo se aplica a cualquier palabra fuera de corpus, no solo a nombres propios y números.

La razón central: para un usuario sordo, una respuesta lenta pero que comunica la palabra es preferible a un rechazo que no comunica nada. El costo de velocidad se acepta a cambio de que el sistema siempre intente decir algo.

Consecuencias:

- **El deletreo deja de ser una funcionalidad opcional y pasa a ser parte del comportamiento central del sistema.** En el backlog estaba registrado (RSK-20) como una épica que solo entraría si sobraba tiempo después de producir las 50 señas, bajo el supuesto de que se activaba solo en casos puntuales (nombres, números). Con este alcance ampliado, el deletreo es el camino de respaldo para *cualquier* palabra fuera de corpus, así que es parte del comportamiento por defecto, no un extra. **Esto queda pendiente de reflejar en el backlog:** hay que decidir si la producción del alfabeto entra en la misma prioridad que el corpus de 50 señas, o si se define una fase intermedia en la que el sistema funciona solo con las 50 señas mientras el alfabeto se produce por separado. Mientras el alfabeto no esté listo, la respuesta real seguirá siendo "Seña no disponible" pese a lo que diga esta decisión.
- Reescribir RF-NLP-02 (INC-01, DOC-02): ya no basta con decir "fuera de corpus retorna Seña no disponible"; hay que describir el

- flujo completo (corpus → deletreo → excepciones, si las hay).
- Los numerales de la LSC no se deletrean como el resto del alfabeto: tienen su propio sistema. Sigue siendo una decisión aparte (DEC-26).
 - Falta definir la cadencia de deletreo (DEC-25): la transición de 0.2 s entre señas del corpus no aplica letra por letra: sin una velocidad definida el "deletrea cualquier palabra" es lento sin límite conocido.
 - Pendiente de validar con el intérprete: si deletrear vocabulario general (no solo nombres) es lingüísticamente razonable en LSC, o si se siente artificial frente a usar una seña real cuando exista. Esta validación es la condición para pasar de **Propuesta** a **Decidida**.
 - Sigue en pie la dependencia de INC-02 (transcripción por streaming): el deletreo solo es tan bueno como la transcripción que lo alimenta, y ahí Whisper es más débil justamente con nombres propios y palabras poco comunes.
-

ADR-002 — Composición del corpus de 50 señas

Responsable: Julián — 40 palabras, falta validar con intérprete. Sergio — validar y agregar más palabras Estado: **En análisis** Fecha: 22/07/2026 Relacionado con: DEC-02, DEC-25, DEC-26, ADR-001, INC-01, TSK-01, TSK-02

Contexto: El corpus debe cubrir un escenario de registro de datos básicos (saludo, preguntas de datos personales, confirmación, despedida), evitando verbos direccionales y señas espaciales (LIM-01).

Trabajo hecho: Se construyó una lista de 24 frases candidatas en español, cada una con categoría, glosa borrador (sin validar) y palabras nuevas que aporta. Total: 40 palabras únicas, sin contar alfabeto ni numerales (ADR-001).

#	Frase en español	Categoría	Glosa (borrador, sin validar)	Palabras nuevas
---	------------------	-----------	-------------------------------	-----------------

1	Hola, bienvenido	Saludo	HOLA BIENVENIDO	HOLA, BIENVENIDO
2	¿Cuál es su nombre?	Pregunta + dato personal	NOMBRE USTED CUÁL	NOMBRE, USTED, CUÁL
3	¿Cuál es su número de documento?	Pregunta + dato personal	DOCUMENTO USTED CUÁL	DOCUMENTO
4	¿Cuál es su fecha de nacimiento?	Pregunta + dato personal	FECHA- NACIMIENTO USTED CUÁL	FECHA- NACIMIENTO
5	¿Cuál es su dirección?	Pregunta + dato personal	DIRECCIÓN USTED CUÁL	DIRECCIÓN
6	¿Esta información es correcta?	Pregunta sí/ no + confirmación	INFORMACIÓN CORRECTO	INFORMACIÓN, CORRECTO
7	Su información fue registrada	Confirmación + verbo de proceso	INFORMACIÓN REGISTRAR	REGISTRAR
8	Por favor espere un momento	Cortesía + confirmación	POR-FAVOR ESPERAR	POR-FAVOR, ESPERAR
9	No entendí, ¿puede repetir?	Confirmación + error	NO ENTENDER REPETIR	NO, ENTENDER, REPETIR
10	Gracias, hasta luego	Despedida	GRACIAS ADIÓS	GRACIAS, ADIÓS
11	¿Cuál es su edad?	Pregunta + dato personal	EDAD USTED CUÁL	EDAD

12	¿Cuál es su correo electrónico?	Pregunta + dato personal	CORREO USTED CUÁL	CORREO
13	¿Dónde vive?	Pregunta + dato personal	VIVIR USTED DÓNDE	DÓNDE, VIVIR
14	¿Cuál es su ciudad?	Pregunta + dato personal	CIUDAD USTED CUÁL	CIUDAD (<i>candidata a fusión con #13</i>)
15	¿Cuál es su ocupación?	Pregunta + dato personal	OCUPACIÓN USTED CUÁL	OCUPACIÓN
16	¿Cuál es su estado civil?	Pregunta + dato personal	ESTADO-CIVIL USTED CUÁL	ESTADO-CIVIL
17	¿Cuál es su teléfono?	Pregunta + dato personal	TELÉFONO USTED CUÁL	TELÉFONO
18	¿Cuál es su sexo?	Pregunta + dato personal	SEXO USTED CUÁL	SEXO
19	Firme aquí, por favor	Verbo de proceso + cortesía	AQUÍ FIRMAR POR-FAVOR	FIRMAR, AQUÍ
20	Necesito ver su documento	Verbo de proceso	DOCUMENTO VER NECESITAR	NECESITAR, VER
21	Escriba su nombre completo	Verbo de proceso	NOMBRE COMPLETO ESCRIBIR	ESCRIBIR, COMPLETO
22	Todo está listo	Confirmación	TODO LISTO	TODO, LISTO

23	¿Tiene alguna pregunta?	Pregunta sí/no	PREGUNTA TENER	TENER, PREGUNTA
24	¿Cómo se llama?	Pregunta + dato personal (<i>alternativa a #2</i>)	COMO LLAMAR	CÓMO, LLAMAR

Notas pendientes para el intérprete:

- Frases 2 y 24: dos formas de preguntar el nombre; elegir una (conecta con INC-01).
- Frases 13 y 14: posible redundancia; si se confirma, libera una palabra.
- USTED y AQUÍ: señalamiento fijo hacia un único rol/lugar, no variable. Falta confirmación lingüística, no técnica.
- Margen actual: 10 palabras libres frente al límite de 50.

Consecuencias:

- No pasa a Propuesta hasta que el intérprete revise vocabulario y orden de glosa.
- El patrón simple del Documento Maestro (Tiempo+Sujeto+Objeto+Verbo) no se está usando para generar estas glosas: la LSC usa estructura tópico-comentario, así que el orden mostrado es borrador, no regla aplicada.

ADR-003 — Origen del avatar y requisitos del esqueleto

Responsable: Samuel Estado; **En evaluación** Bloqueada por: TSK-04
Fecha: 22/07/2026 Relacionado con: DEC-03, DEC-04, DEC-09, RSK-12

Contexto: el avatar necesita huesos suficientes en los dedos (configuración manual) y controles faciales (MNM). No es una elección entre alternativas todavía, sino verificación: confirmar si existe un avatar

accesible que cumpla esos dos requisitos.

Qué debe confirmar TSK-04: si hay un avatar con ese rig disponible, o si hace falta uno hecho a la medida. Hipótesis de trabajo: manos animadas a mano en Blender, captura de movimiento solo para tronco y brazos.

ADR-004 — Proceso de producción de animaciones

Responsable: Samuel **Estado:** En evaluación **Bloqueada por:** TSK-04
Fecha: 22/07/2026 **Relacionado con:** DEC-04, RSK-12

Contexto: no está definido cómo se van a producir las señas del corpus, ni cuánto tarda cada una. No hay alternativas que comparar todavía: hace falta el dato antes de poder decidir un proceso.

Qué debe confirmar TSK-04: cuánto tarda producir una seña completa y validada. Ese número determina si el proceso elegido cabe en las tres semanas de la Fase 3.

ADR-005 — Estrategia de transcripción en vivo

Responsable: Sergio **Estado:** En evaluación **Bloqueada por:** TSK-03
Fecha: 22/07/2026 **Relacionado con:** DEC-05, INC-02, INC-21

Contexto: mostrar texto mientras la persona habla, no solo al final.

Opciones identificadas:

- Ventana deslizante con detector de voz (VAD): reprocesa audio reciente cada cierto tiempo.
 - Envío por bloques con traslape: manda fragmentos que se superponen para no cortar palabras.
 - Herramienta ya armada para esto (ej. faster-whisper con soporte de parciales) en vez de construirlo desde cero.
-

ADR-006 — Modelo de Whisper y entorno de ejecución

Responsable: Sergio **Estado:** En evaluación **Bloqueada por:** TSK-03
Fecha: 22/07/2026 **Relacionado con:** DEC-06, INC-04, INC-17

Contexto: Whisper tiene varios tamaños de modelo; hay que elegir uno que quepa y rinda en la RTX 3050.

Opciones identificadas:

- Modelo pequeño (base/small): rápido y liviano, menos preciso.
 - Modelo mediano (medium): balance intermedio.
 - Modelo grande (large-v3): más preciso, puede no caber en la VRAM disponible.
-

ADR-007 — Enfoque de NLP

Responsable: Julián **Estado:** En evaluación **Bloqueada por:** TSK-05
Fecha: 22/07/2026 **Relacionado con:** DEC-07, DEC-16, RSK-03, RSK-04

Contexto: convertir español a glosas del corpus.

Opciones identificadas:

- Solo LLM: se adapta mejor a distintas formas de decir lo mismo, pero es más lento, tiene costo por uso y no siempre da la misma respuesta.
 - Solo reglas: rápido, gratis, siempre da el mismo resultado, pero solo cubre lo que se programe explícitamente.
 - Reglas primero, LLM como respaldo cuando las reglas no alcanzan: intenta combinar velocidad y consistencia con flexibilidad.
-

ADR-008 — Que el NLP indique el tipo de frase

Responsable: Julián **Estado:** Propuesta **Fecha:** 22/07/2026

Relacionado con: DEC-08, DEC-09, DEC-10, INC-03

Contexto: las expresiones faciales (MNM) van sobre toda la frase, no sobre una seña sola. El backend necesita saber si la frase es afirmativa, interrogativa o negativa para poder aplicarlas.

Decisión: el NLP agrega un campo con el tipo de frase a su salida, independiente de si el NLP termina siendo LLM, reglas o híbrido (DEC-07). Ese campo debe viajar desde el NLP hasta el Validador/ mapeador y quedar en el JSON final (DEC-10).

Consecuencias:

- Falta definir los valores exactos del campo. Con lo visto en ADR-002, probablemente no basta con "pregunta sí/no": hay preguntas de contenido (con palabra interrogativa) y de sí/no (solo MNM, sin palabra), y podrían necesitar tratamiento distinto.
 - Pendiente de validar con el intérprete qué patrones de MNM corresponden a cada tipo.
-

ADR-009 — Expresiones faciales como capa independiente

Responsable: Juan Diego **Estado:** **Propuesta** **Fecha:** 22/07/2026
Relacionado con: DEC-09, DEC-03, DEC-08

Contexto: cómo se aplica la expresión facial en Filament sin mezclarla con la animación de cada seña.

Decisión: la animación se separa en dos capas: una esquelética (manos, brazos, cuerpo) por seña, y una facial que se aplica sobre toda la secuencia mientras dure la frase, según el tipo de frase de ADR-008.

Consecuencias:

- Depende de que el avatar tenga controles faciales suficientes (DEC-03, bloqueada por TSK-04). Si TSK-04 no encuentra un rig adecuado, este enfoque debe revisarse.
 - No pasa a Decidida hasta confirmar esa capacidad del rig.
-

ADR-010 — Contrato JSON definitivo entre backend y avatar

Responsable: Juan Diego **Estado:** En análisis **Fecha:** 22/07/2026
Relacionado con: DEC-10, DEC-08, DEC-09, DEC-12, INC-03, INC-07, INC-14

Contexto: el mensaje final que arma el Validador/mapeador y envía al cliente, reemplazando el contrato mínimo de tres campos (`glosa`, `orden`, `ruta_animacion`) que hoy es insuficiente.

Por qué sigue en análisis: depende de que cierren primero ADR-008 (campo de tipo de frase), ADR-009 (cómo se referencia la capa facial) y DEC-12 (si el GLB es único o por seña, descargado o embebido), que todavía no se ha tocado.

Consecuencias: cuando esas tres cierren, aquí se consolida el esquema final, incluyendo cómo se representa una secuencia de deletreo (ADR-001).

ADR-011 — Número de microservicios y ubicación de las fronteras

Responsable: Julián **Estado:** Decidida (el enfoque) / la descomposición concreta queda pendiente **Fecha:** 22/07/2026 **Relacionado con:** DEC-11, DEC-21, INC-06, TSK-08

Contexto: el Documento Maestro habla de "microservicios" sin definir cuántos ni dónde van los cortes, y hay una contradicción (INC-06) sobre si el gestor de animaciones vive en el servidor o en el cliente.

Decisión: se mantiene el enfoque de microservicios, no un monolito. Es una decisión ya tomada por el equipo porque es un objetivo declarado de la tesis, aceptando el costo operativo adicional que eso implica (LIM-07). Se acordó minimizarlo con pocos servicios, sin transacciones distribuidas entre ellos, y con despliegue y observabilidad centralizados.

Qué falta y depende de TSK-08: el número exacto de servicios y dónde va cada frontera. La separación más clara hasta ahora es por perfil de recursos: STT necesita GPU y puede escalar aparte; NLP y el Validador/mapeador son más livianos. Falta decidir si van en un solo servicio o en dos, y confirmar que el gestor de animaciones (INC-06) vive en el servidor, resolviendo esa contradicción.

Consecuencias:

- DEC-21 (cómo demostrar que los microservicios sirven) no se puede cerrar hasta que esta descomposición esté definida: no se pueden medir métricas de escalado o aislamiento de fallos sin saber cuántos servicios hay.
 - TSK-08 es quien produce esa descomposición concreta; cuando cierre, se actualiza este ADR con el detalle.
-

ADR-012 — Estrategia de archivos GLB

Responsable: Juan Diego **Estado:** **Propuesta** Bloqueada por: TSK-04
Fecha: 22/07/2026 **Relacionado con:** DEC-12, DEC-10, INC-14, TSK-04

Contexto: hay que decidir cómo se empaquetan y entregan los archivos 3D de las 50 animaciones entre el servidor y el cliente. El Documento Maestro tiene una contradicción de tamaños (INC-14): pide un GLB de máximo 25 MB, pero también menciona "50 animaciones en un único GLB" y estima 5-10 MB por seña, lo que da hasta 250 MB en total — diez veces el límite.

Propuesta del equipo: un archivo GLB por seña, no uno solo con todas. El flujo de producción sería: cada seña se graba como video en Plask.ai, se convierte a GLB, y ese archivo se guarda en el repositorio y se referencia en la base de datos mediante `ruta_animacion_glb` (que además ya existe en el esquema de §7.2, así que esto encaja con lo que ya estaba definido ahí).

Punto técnico que hay que resolver antes de confirmar esto: el peso real de cada GLB depende de qué contiene. Hay dos formas de hacerlo:

1. **Cada GLB incluye el avatar completo** (malla, texturas, esqueleto) más la animación de esa seña. Si se hace así, el avatar completo se repite en los 50 archivos. Si el avatar pesa unos pocos MB, repetirlo 50 veces puede sumar más de 100 MB solo en avatar duplicado, sin contar las animaciones — es decir, se reproduce el mismo problema de INC-14 aunque ya se hayan separado los archivos.
2. **El avatar se carga una sola vez** al iniciar la app (malla, texturas, esqueleto), y cada GLB de seña contiene únicamente el movimiento de los huesos para esa animación, sin repetir geometría ni texturas. Con esta separación, cada archivo de animación puede pesar apenas unos kilobytes en vez de varios megabytes, porque solo son datos de movimiento, no modelos 3D completos.

La opción 2 es la que realmente resuelve INC-14 y además hace viable §9.1, que pide cargar las 50 animaciones al inicio de la sesión — mucho más realista si son archivos livianos.

Lo que no se sabe todavía: si Plask.ai exporta animaciones ya separadas de la malla, o si cada exportación viene con el avatar completo incluido y hay que separarlo manualmente en Blender después. Esto no se puede resolver por discusión, hay que probarlo.

Decisión: se adopta un archivo GLB por seña, referenciado en la base de datos. Queda como Propuesta y no como Decidida porque falta confirmar si se puede lograr la separación de malla y animación (opción 2), que es la que hace viable el enfoque completo.

Consecuencias:

- TSK-04 debe agregar, además de lo que ya tenía a cargo (medir tiempo de producción de una seña), verificar si el flujo de Plask + Blender permite exportar solo el movimiento de huesos por separado del avatar.
- Si no es posible separar malla y animación, hay que revisar de nuevo INC-14: puede que haga falta comprimir el avatar, reducir el número de animaciones cargadas simultáneamente, o replantear el límite de 25 MB.
- DEC-10 (contrato JSON) queda a la espera de esta decisión: el

significado del campo `ruta_animacion` depende de si apunta a un archivo independiente por seña (como se propone aquí) o a una animación dentro de un archivo compartido.

ADR-013 — Tratamiento del audio y el texto

Responsable: Samuel **Estado:** En análisis **Fecha:** 22/07/2026

Relacionado con: DEC-13, INC-05

Contexto: el sistema procesa voz y transcripciones que incluyen datos personales (nombres, documentos, fechas de nacimiento), y parte de ese contenido se envía a un LLM externo, posiblemente fuera de Colombia. Falta definir si se guarda o se borra el audio y el texto, por cuánto tiempo, si se anonimiza, y bajo qué base legal se justifica el envío al proveedor externo (Ley 1581 de 2012).

Pendiente: discutir opciones y fijar una política antes de probar con usuarios reales.

ADR-014 — Seguridad del backend y control de gasto del LLM

Responsable: Sergio **Estado:** En análisis **Fecha:** 22/07/2026

Relacionado con: DEC-14, DEC-20, INC-20, RSK-16

Contexto: hay que proteger el backend de mal uso, y en particular evitar que alguien externo genere peticiones sin control y dispare el gasto del LLM, que se paga por uso. El único mecanismo hoy propuesto es limitar por IP, que falla detrás de redes compartidas (INC-20) y no resuelve el problema de fondo.

Pendiente: depende de que DEC-20 (definición de sesión e identificación del cliente) esté resuelta primero, porque cualquier mecanismo de control necesita saber cómo se identifica a un cliente.

(el resto de las decisiones se agregan a medida que se trabajan)

Historial

Versión	Fecha	Cambios
0.1	22/07/2026	Creación del documento: plantilla e índice de las 26 decisiones pendientes.
0.2	22/07/2026	Se agrega explicación de qué es un ADR. Se agrega TSK al campo "Relacionado con" de la plantilla.
0.3	22/07/2026	Se agrega ADR-001 (alcance del deletreo), estado Propuesta.
0.4	22/07/2026	Se agrega ADR-002 (corpus candidato, 24 frases / 40 palabras), estado En análisis.
0.5	22/07/2026	Se agrega estado "En evaluación". Se agregan ADR-003, 004, 005 (DEC-05, 06, 07) con opciones identificadas, pendientes de TSK-03/TSK-05.
0.6	22/07/2026	Se renumeran los ADR para que coincidan con su DEC (ADR-005=DEC-05, etc.). Se agrega campo "Bloqueada por" a la plantilla, visible justo debajo del estado. Se agregan ADR-003 (DEC-03) y ADR-004 (DEC-04), bloqueados por TSK-04.
0.7	22/07/2026	Se agregan ADR-008 y ADR-009 (Propuesta) y ADR-010 (En análisis, depende de las anteriores y de DEC-12).
0.8	22/07/2026	Se agrega ADR-011 (microservicios, enfoque decidido, descomposición pendiente de TSK-08) y ADR-012 (GLB por seña, Propuesta, pendiente de confirmar separación malla/animación en TSK-04).

0.9	22/07/2026	Se agregan ADR-013 y ADR-014 (En análisis, contexto sin discutir opciones todavía). ADR-014 depende de que DEC-20 esté resuelta primero.
0.10	22/07/2026	Se agrega campo "Responsable" a la plantilla y a los ADR-001 a ADR-014, con el estado de avance de cada uno según lo indicado por el equipo.